Лабораторная работа №1 Хранение переменных в С++ Изучение особенностей переменной float

Информатика, 1-й семестр Дудин Иван Юрьевич Б03-304 30 сентября 2023г.

1. Введение

Цель:

Изучение и оценка стандартного формата чисел с плавающей точкой в языке программирования C++. Получение фундаментального понимания того, что происходит с вещественными числами при выполнении операции над ними в языке программирования C++.

Метод изучения:

Экспериментальное выполнение поставленных в процессе работы заданий в компиляторе языка программирования C++ "CodeBlocks". Анализ открытых источников и форумов, посвященных языку программирования, из интернета, с целью получения новой информации и ее последующего использования при выполнении лабораторной работы. Визуальное отображение результатов эксперимента в форме графиков в прямоугольной системе координат, построенных в компиляторе "РуCharm" языка программирования Руthon.

2. Основная часть

Задание 1: Перевод числа из десятичной системы счисления в двоичную

Основная задача: преобразование числа формата *unsigned int* в *binary* при помощи побитового сдвига числа *char*

Описание работы: изначально, было необходимо написать код, который переводит число из десятеричной системы в двоичную с помощью математических операций. Однако данный код неоднократно был мною прописан в контестах №1-3, поэтому моя цель состояла в написании такого кода, который либо вовсе не использует, либо выполняет только основные математические операции (сложение или умножение), но при этом всем выводит двоичную запись любого заданного пользователем десятеричного числа.

Рисунок 1: Первая версия перевода в двоичную систему

```
#include <iostream>
using namespace std;
union un {
    int i;
    float f;};
void binary(unsigned int n)
    for (int i=1; i<=32; i++)
        {if ((n<<1)>>1==n)
            {cout<<0;}
        else
            {cout<<1;}
        n=n<<1; }
int main()
    un t;
    cin >> t.f;
    binary(t.i);
    cout << endl;
}
```

Рисунок 2: Вторая версия перевода в двоичную систему

```
#include <iostream>
using namespace std;
int main()
{
    unsigned int s;
    cin>>s;
    for(int i=0;i<32;i++)
    {
        if (s==((s<<1)>>1))
            cout<<"0";
        else
            cout<<"1";
        s=s<<1;
    }
}</pre>
```

Оба кода выполняют корректный перевод в двоичную запись. Первая версия содержит в себе функцию перевода числа и строку *union*, из-за чего она более удобна для написания дальнейшей программы.

Вторая же версия не содержит себе ничего из этого, но при этом все она более компактна.

Таблица 1: Проверка первого задания на практике

Введенное значение	Полученный результат	Ожидаемый результат	
0	000000000000000000000000000000000000000	000000000000000000000000000000000000000	+
1	000000000000000000000000000000000000000	000000000000000000000000 0000001	+
343	00000000000000000000000000000000000000	00000000000000000000000000000000000000	+
235467	000000000000001110010111	000000000000001110010111 11001011	+
f	000000000000000000000000000000000000000	NaN	土
100000000	001110111001101011001010 00000000	001110111001101011001010 00000000	+
-7	11111111111111111111111111111111111111	11111111111111111111111111111111111111	+
4294967296	11111111111111111111111111111111111111	NaN	_
-1	111111111111111111111111111111111111111	11111111111111111111111111111111111111	+

Большинство результатов оказались ожидаемыми, однако некоторые сработали не так, как планировались. При введении символа в числовую переменную мною ожидалось ошибка компилятора, однако он обнулил эту переменную. При введении числа, большего чем допустимого значения *unsigned int*, я ожидал ошибку компилятора, однако он считал его числом выше порога на "-1" и поэтому вывел двоичный код для числа "-1". Таким образом можно сделать вывод, что при вводе отрицательного числа, программа прибавляет слева к двоичной записи числа "1", обнуляя последующие знаки. После чего из данного значения вычитает модуль отрицательного числа и выводит его на экран. Аналогично работает с теми числами, которые больше порогового значения *unsgined int*, только вычитается не просто число, а модуль разности максимального значения "4294967295"(2³²-1) и введенного числа.

Задание 2: Переполнение мантиссы

Основная задача: воспроизвести переполнение мантиссы и оценить полученные результаты

Описание работы: на основе перевода числа в двоичную запись были изучены результаты для степеней числа 10. Пример кода используемого кода изображен на риснуке 3

В рисунке 4 представлены результаты для цикла до сороковой степени числа 10.

Были получены весьма любопытные результаты:

До значения 10^{10} результаты были предсказуемы и являются корректными, после чего со значениями начинается происходить что-то непонятное. Значение переменной *float* становится не равной степени числа 10, но все еще является сильно приближенно к ней. Это связано с дискретностью диапазона float — в нем представимы далеко не все вещественные числа. Даже те числа, которые в десятичном разложении выглядят «нормально» - степени десятки или та же 0.2 — могут быть непредставимы во float. А значит, все вычисления у вас будут идти с какой-то погрешностью, потому что заранее предсказать, где там обрежется какой хвост у числа, практически невозможно. Погрешность невелика, но она может накапливаться и полностью менять расчет при больших количествах операций.

С двоичной записью числа вопросов практически не возникает. При значении выше порога программа преобразует число в разность, однако если из порогового значение a вычесть число k>>2a, их разность превзойдет даже отрицательный порог двоичной записи, и компилятор, ожидаемо, выведет 0.

Также стоит отметить, что при значение больше чем 10^{38} переменная вида *unsigned int* достигает своего порога и не считывает переменную вовсе.

Рисунок 3: Пример кода для изучения свойств мантиссы

```
#include <iostream>
using namespace std;
union un {
    int i;
    float f;
};
void binary(unsigned int n)
for (int i=1; i<=32; i++) {
     if ((n<<1)>>1==n)
    cout<<0;
}
else
{
    cout<<1;
}
n=n<<1; }
int main()
{
    cout << fixed;
    cout.precision(2);
    un t,1;
    1.f=1.0;
    int n=1;
    for(int i=0;i<40;i++){
        1.f=1.f*10;
        cout<<(1.f);
        cout<<endl;
        binary(1.f);
        cout<<endl;
        cout<<endl;
    }
}
```

Рисунок 4: Результаты 2-го задания для чисел от 10 до 10^{40}

00000000000000000000000000001010100.00 000000000000000000000000011001001000.00 000000000000000000000111110100010000.00 0000000000000000010011100010000100000.00 00000000000000110000110101000001000000.00 000000000001111010000100100000010000000.00 0000000100110001001011010000000100000000.00 00000101111110101111100001000000001000000000.00 00111011100110101100101000000000010000000000.00 01010100000010111110010000000000099999997952.00 0100100001110110111000000000000000999999995904 00 9999999827968.00 01001110011100000000000000000000000100000000376832.00 999999986991104.00 10000000272564224.00 99999998430674944.00 999999984306749440.00 9999999980506447872.00 100000002004087734272.00 1000000020040877342720.00 999999778196308361216.00 9999997781963083612160.00 1000000013848427855085568.00

10000000714945030854279168.00

100000002537764290115403776.00

1000000062271131048573140992.00

10000000622711310485731409920.00

100000001504746621987668885504.00

100000017017155010075500077010

1000000015047466219876688855040.00

999999848243207295109594873856.00

100000003318135351409612647563264.00

1000000071866979741764260066230272.00

10000000409184787596297531937521664.00

100000004091847875962975319375216640.00

1000000040918478759629753193752166400.00

10000000567641112624826207124609564672.00

100000006944061726476491472742798852096.00

inf

inf

Задание 3: Создание бесконечного цикла

Основная задача: Создание бесконечного цикла на базе ошибки вычисления числа unsigned int.

Описание работы: в задании 2 было замечено, что при больших значениях unsigned int переменная, как бы, "ломается" и присваивает себе не абсолютно точные, а лишь приближенные значения. Поэтому, из-за данной особенности может возникнуть ситуация, когда цикл не прерывается, потому что переменная не достигает определенного значения. Пример подобного кода изображен на рисунке 5.

Рисунок 5: Пример бесконечного цикла, вызванного особенностями

переменной unsigned int

```
#include <iostream>
using namespace std;
union un {
    int i;
    float f;
void binary(unsigned int n)
for (int i=1; i<=32; i++) {
     if ((n<<1)>>1==n)
    cout<<0;
}
else
    cout<<1;
 n=n<<1; }
int main()
    cout << fixed;</pre>
    cout.precision(2);
    un t,1;
    int k;
    1.f=21300000000.0;
    for(;l.f<(l.f+1);l.f++)
        {cout<<k<<")everlasting cycle"<<endl;
        k++:
        if(k==6)
            break;
}
```

Рисунок 6: Появление бесконечного цикла

1)everlasting cycle 2) everlasting cycle 3)everlasting cycle 4) everlasting cycle 5) everlasting cycle

Как можно заметить, код, изображенный на рисунке 5, должен иметь всего один шаг в цикле, ведь счетчик увеличивается за раз на единицу, а ограничителем стоит число, большее счетчика на единицу. Но в результате данного значения не достигается, и код бы выводил cout бесконечно (если бы не break). Причина данного явления отображена в

пункте "Задание 2" и заключена в особенности переменной вида *unsigned int*.

Задание 4: График числа π

Основная задача: Изучение способов нахождения числа π, попытка экспериментального подтверждения расчетов с помощью языка программирования C++, построение графика зависимости значения числа π от количества итераций.

Описание работы: В былые времена многие математики пытались найти способ вычислить число π с наибольшей точностью. И для этого придумывались громоздкие формулы, производились сложнейшие вычисления и, стоит отметить, достигались довольно точные значения константы. Однако сейчас можно просчитать формулы всего за несколько минут с помощью того же самого языка программирования C++.

Стоит отметить, что в данном пункте все значения и все шаги итераций выполнялись на языке программирования C++. В Python были только построены графики.

4.1: Серия Мадхавы

Первая изученная мною итерационная формула - это серия Мадхавы для числа π .

$$\pi = \sqrt{12} \left(1 - \frac{1}{3 \cdot 3} + \frac{1}{5 \cdot 3^2} - \frac{1}{7 \cdot 3^3} + \cdots \right)$$

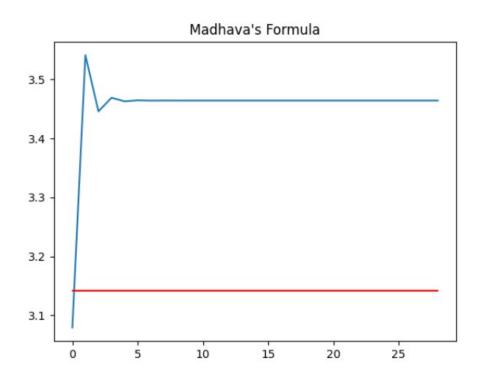
На рисунке 7 изображен код для обработки данной формулы.

График зависимости значения числа от итераций изображена на рисунке 8, где синяя ломанная - значение переменной, а красная - ожидаемая константа. Здесь сразу же можно заметить несостыковку - полученный результат очень сильно отличается от реального значения числа π. Причину этого я вижу в переменной *float*. В процессе вычисления складываются и умножаются числа с большим количеством цифр после запятой. Ранее уже было замечено такое свойство у переменных *unsigned int*, когда переменной присваивается не абсолютно точное, а приближенное значение из-за чего возникает погрешность. В данном же случае данная несостыковка оказалась крайне значимой, что можно увидеть на рисунке 8.

Рисунок 7: Код для выполнения уравнения Мантиссы

```
#include <iostream>
#include <cmath>
#include <iomanip>
#include <fstream>
using namespace std;
int main()
    ofstream f("methodMadhava.txt", ios::out);
    float abv;
    float abc;
    abv=1.0;
    abc=0.0;
    int above=1;
    for (float i=1;i<30;i=i+1){
        abv=1.0+pow(-1,i)/((1.0+2.0*i)*pow(3,i));
        cout<<"Number of iteration:"<<above<<endl;</pre>
        cout<<fixed<<setprecision(10)<<pow(12.0,1.0/2.0)*abv<<endl;</pre>
        f<<pow(12.0,1.0/2.0)*abv<<endl;
        above++;
    }
}
```

Рисунок 8: График зависимости по уравнению Мантиссы в С++



4.2 Формула Валлиса

Далее я рассмотрел формулу Валлиса для нахождения значения числа π .

$$\prod_{n=1}^{\infty} \frac{(2n)(2n)}{(2n-1)(2n+1)} = \frac{\pi}{2}$$

На рисунке 9 изображен код для выполнения итераций согласно формуле Валлиса.

Рисунок 9: Формула Валлиса в С++

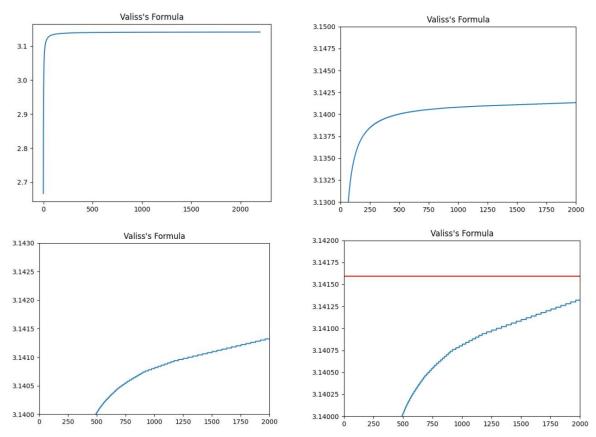
```
#include <iostream>
#include <cmath>
#include <iomanip>
#include <fstream>
using namespace std;
int main()
{
    ofstream f("0methodValiss.txt", ios::out);
    float abv;
    float abc;
    abv=1.0;
    abc=0.0;
    int above=1;
    for (float i=1;i<2200;i=i+1){
        abc=(4.0*i*i)/(4.0*i*i-1);
        abv=abv*abc;
        cout<<"Number of iteration:"<<above<<endl;
        cout<<fixed<<setprecision(10)<<abv*2<<endl;</pre>
        f<<abv<<",";
        above++;
    }
```

На рисунках 10-13 можно увидеть зависимость полученного значения от числа итераций

Как можно увидеть, с данной последовательностью не возникает ситуации подобной последовательности Мадхавы. Здесь значение на протяжении большого количества итераций сходится к числу π , однако при очень больших количествах шагов полученное значение калибруется крайне малым значениями, которые переменная *unsigned int* лишь приближает к

точному, из-за чего последовательность "притупляется" и по итогу сводится к не совсем точному значению 3,14135

Рисунки 10-13: Графики зависимости значения числа от количества итераций для формулы Валисса в различных масштабах



В качестве эксперимента было замерено время, при котором получаются те или иные цифры числа π . Они отмечены в таблице 2, и стоит отметить, что результаты довольно любопытные.

Таблица 2: Время, необходимое для получения той или иной цифры числа π по формуле Валисса

Необходимая точность значения	Количество итераций	Затраченное время
3.1	19	0.000 c
3.14	493	0.000 c
3.141	1315	0.000 c

Время для каждого числа - 0.000с. Опыт был проведен неоднократно, однако результат оказался тем же. Объяснить данный итог я могу следующим образом: из-за того, что для метода Валлиса выполняются простейшие операции над числами, их итог выводится крайне быстро, из-за чего компилятор просто не в силах вывести настолько малое значение времени, поэтому и выводится значение 0.

Для вывода времени использовалась команда: "Time taken: %.6fs\n", (double)(clock() - tStart)/CLOCKS_PER_SEC при использовании import <time.h>

4.3 Формула Виета

$$\frac{2}{\pi} = \frac{\sqrt{2}}{2} \cdot \frac{\sqrt{2+\sqrt{2}}}{2} \cdot \frac{\sqrt{2+\sqrt{2}+\sqrt{2}}}{2} \cdot \dots$$

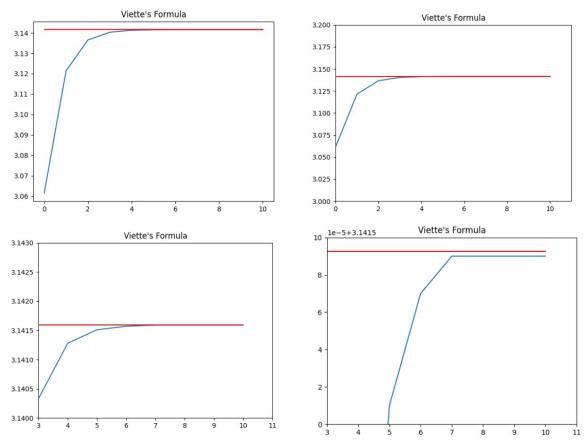
На рисунке 14 изображен код для вычисления числа π по формуле Виета.

Рисунок 14: Код для нахождения числа π по формуле Виета

```
#include <iostream>
#include <cmath>
#include <iomanip>
#include <fstream>
using namespace std;
int main()
    ofstream f("methodViette.txt", ios::out);
    float abv;
    float abc;
    abv=pow(2,1.0/2);
    abc=0.0;
    float itog;
    itog=2.0/pow(2,1.0/2);
    float mi;
    mi=-1.0;
    float c;
    c=0.0;
    int above=1;
    for (float i=1;i<12;i=i+1){
        abc=pow(2+abv,1.0/2);
        abv=abc;
        itog=itog*(2/abv);
        cout<<"Number of iteration:"<<above<<endl;</pre>
        cout<<fixed<<setprecision(10)<<itog*2<<endl;</pre>
        f<<itog*2<<endl;
        mi = -1.0;
        c=c+1.0;
        above++;
    }
}
```

На рисунках 15-18 можно увидеть графики зависимости значения числа от количества итераций

Рисунки 15-18: График зависимостей значения числа от количества итераций по формуле Виета в различных масштабах



Можно сразу же отметить, что формула Виета получает число π при крайне малом количестве итераций, это можно увидеть в таблице 3:

Таблица 3: Время, необходимое для получения той или иной цифры числа π по формуле Виета

Необходимая точность значений	Количество итераций	Затраченное время
3.1	2	0.000 C
3.14	4	0.000 C
3.141	5	0.000 C
3.1415	6	0.000 C
3.14159	8	0.000 C

Здесь повторилась та же ситуация, что наблюдалась для формулы Валлиса. Однако точное значение получается при очень малом количество итераций, после чего она сходится к 3.14159 и далее перестает давать точное значение. А так как малое количество итераций занимает крайне малое время, компилятор выводит значение 0.000 сек.

4.4 Формула Лейбница

$$\frac{\pi}{4} = 1 - \frac{1}{3} + \frac{1}{5} - \frac{1}{7} + \frac{1}{9} - \dots$$

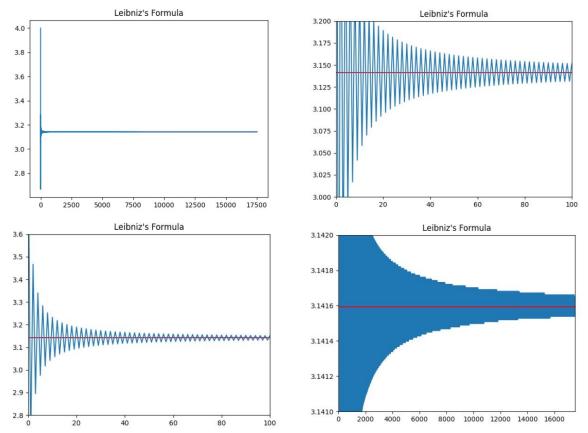
На рисунке 19 изображен код для нахождения числа π по методу Лейбница.

Рисунок 19: Код для нахождения числа π по формуле Лейбница

```
#include <iostream>
#include <cmath>
#include <iomanip>
#include <fstream>
using namespace std;
int main()
    ofstream f("methodLeibniz.csv", ios::out);
    float abv;
    float abc;
    abv=0.0;
    abc=0.0;
   float mi;
   mi=-1.0;
   float c;
    c=0.0;
    int above=1;
    for (float i=0;i<100000;i=i+2){
        for(float k=0;k<=c;k=k+1.0){
            mi=mi*(-1.0);
        abc=4/(i+1)*mi;
        abv=abv+abc;
        cout<<"Number of iteration:"<<above<<endl;</pre>
        cout<<fixed<<setprecision(10)<<abv<<endl;</pre>
        f<<abv<<endl;
        mi = -1.0;
        c=c+1.0;
        above++;
    }
}
```

На рисунках 20-23 можно увидеть графики зависимости значения числа от количества итераций

Рисунки 20-23: График зависимостей значения числа от количества итераций по формуле Лейбница в различных масштабах



Используя формулу Лейбница, компилятор выводит каждый раз значения, которые колеблются около числа π. Однако для этого необходимо большое число итераций и в конечном счете выводится чередование 3.14162, 3.14158. На таблице 4 представлены время и количество и итераций для этого:

Таблица 4: Время, необходимое для получения той или иной цифры числа π по формуле Лейбница

Необходимая точность значений	Количество итераций	Затраченное время
3.1	19	0.013 c
3.14	119	0.034 c
3.141	1696	0.516 c
3.1415	10200	3.215 c

Можно заметить, что в отличие от предыдущих формул, здесь компилятору требуется какое-то время для получения результата.

Таким образом можно сделать вывод, что наиболее точный и быстрый способ найти число π - это формула Виета, она получает значение с точностью до 5 цифры после запятой все за 8 итераций. Если же

необходимо получить красивый график, демонстрирующий то, как последовательность стремится к значению числа π , то лучше всего использовать формулу Лейбница. Однако следует помнить, что переменные вида *unsigned int* и *float* при больших или наоборот малых значениях выдают не абсолютно точный, а приближенный результат, из-за чего выдается не совсем точное, а лишь приближенное значение, поэтому на определенном шаге значение числа престает меняется и принимает лишь приближенное к числу π значение.

3. Подведение итогов

Таким образом, изучив особенности переменных вида unsigned int и float можно констатировать следующее:

- 1. Данные переменные удобны для работы и выполнения математических операций, если их значения не является очень большим или очень малыми
- 2. При очень малых или очень больших значениях переменных она принимают не абсолютно точные, а лишь приближенные значения. Это не вызывает проблем для обычного пользователя, но если необходимо с данными числами провести какие-либо операции, требующие абсолютной точности, то с этим могут возникнуть определенные проблемы из-за появления такой погрешности у переменных

Язык программирования C++ позволяет проводить очень громоздкие вычисления за малый промежуток времени, в этом он удобен для создания, например, каких-либо игр. Если же говорить о математических расчетах, опять же, требующих абсолютной точности, то по моему мнению, к плюсам в этом деле нужно относиться с крайней осторожностью.